



Diplomado Superior en Ciencia y Analítica de Datos Examen: Módulo IV

Instrucciones generales

Este examen está diseñado para evaluar tu capacidad de aplicar las técnicas del Módulo IV en escenarios reales vinculados al análisis histórico, sociológico y de divulgación científica. Deberás demostrar dominio en procesos de ingeniería de datos (ETL, cruces y versionado en la nube), visualización de datos, modelado de lenguaje natural y desarrollo de aplicaciones interactivas.

El examen consta de dos partes independientes. Cada una plantea un reto técnico con enfoque práctico. Se valorará tu capacidad para comunicar hallazgos, justificar decisiones analíticas y construir soluciones funcionales. Se recomienda cuidar la presentación, ortografía y redacción técnica.

Objetivo

Aplicar tus conocimientos para resolver problemas reales relacionados con el análisis del conocimiento global, generando productos útiles para la divulgación, la investigación y la formulación de políticas científicas.

Parte 1: Integración de Datos en la Nube y Dashboard Interactivo de los Premios Nobel

Introducción del caso

Has sido contratado como consultor de datos por la Fundación Nobel con el fin de analizar el histórico de los galardones otorgados desde su creación. El objetivo es entender las dinámicas globales de la excelencia científica y literaria, identificar brechas históricas (geográficas, de género o por disciplinas) y evaluar cómo se ha distribuido el reconocimiento a lo largo del tiempo.

Fase Previa: Integración y Carga de Datos en la Nube (ETL y GitHub)

Antes de construir el tablero visual, deberás consolidar la información histórica a partir de dos conjuntos de datos independientes:

1. Un conjunto de datos que incluye la información biográfica y general de los ganadores. Este conjunto de datos se obtendrá de la siguiente dirección URL:
https://raw.githubusercontent.com/anaepm/rep/refs/heads/main/nobel_personal.csv
2. Un conjunto de datos que proporciona los detalles específicos de cada galardón, categorías y motivaciones oficiales. La dirección URL de este conjunto de datos es:
https://raw.githubusercontent.com/anaepm/rep/refs/heads/main/nobel_data.csv



Tu tarea en esta fase consiste en:

1. **Realizar el Join:** Utilizando Python (Google Colab), carga ambos datasets mediante las fuentes públicas correspondientes, realiza un cruce (join) adecuado utilizando las llaves de 'Firstname' y 'Lastname' para unificar la información en una sola tabla consolidada.
2. **Exportar y Publicar:** Guarda el resultado como un único archivo limpio en formato CSV y súbelo a un repositorio público en tu cuenta de GitHub.
3. **Obtener la URL Raw:** Genera y copia el enlace directo RAW de tu archivo en GitHub, el cual se utilizará como fuente de datos en vivo.

Objetivo del Dashboard (Power BI)

Utilizando Power BI, CONÉCTATE DIRECTAMENTE A LA DIRECCIÓN RAW de GitHub que generaste para importar los datos en tiempo real y construye un dashboard interactivo que permita visualizar:

- La distribución histórica de los premios por categoría (Física, Química, Medicina, Literatura, Paz, Economía).
- La evolución temporal de la concesión de premios y las tendencias de género.
- Comparaciones geográficas (países con mayor número de laureados e instituciones de afiliación).
- Patrones o correlaciones relevantes (por ejemplo, edad promedio de los laureados al momento de recibir el premio según la disciplina).
- Cualquier otro hallazgo relevante que consideres útil para la toma de decisiones o la divulgación pública.

Entregable 1

Deberás adjuntar el archivo del dashboard con extensión .pbix.

Parte 2: Modelo de Predicción de Categorías del Premio Nobel basado en Texto (con Streamlit)

Introducción del caso

El registro histórico de los Premios Nobel resguarda la memoria de las contribuciones más importantes de la humanidad. Cada galardón va acompañado de una motivación oficial —un breve texto redactado por los comités académicos que describe con precisión el descubrimiento, avance o impacto del ganador—.

La Fundación Nobel y los comités de análisis historiográfico están interesados en evaluar si la terminología, el enfoque conceptual y el vocabulario técnico utilizados en estas descripciones reflejan patrones tan distintivos que es posible automatizar su clasificación disciplinaria.

Como parte de tu colaboración, se te ha asignado el desarrollo de una herramienta interactiva que permita predecir la categoría del Premio Nobel (por ejemplo: Física, Química, Medicina, Literatura, Paz, etc.) a partir del texto de la motivación o de una descripción provista por el usuario.



Tu tarea consiste en:

1. **Realizar el proceso ETL de Texto:** Extrae, limpia, normaliza y procesa el texto de las motivaciones históricas de los Premios Nobel (limpieza de caracteres especiales, conversión a minúsculas, eliminación de stopwords y vectorización mediante técnicas como TF-IDF o embeddings de texto).
2. **Construir el modelo predictivo:** Diseña y entrena un modelo de aprendizaje automático (como Regresión Logística, Naive Bayes o Random Forest aplicado a texto) para PREDECIR LA CATEGORÍA del premio en función de los términos clave de la motivación. Evalúa su rendimiento mediante métricas de clasificación, incluyendo la matriz de confusión.
3. **Desarrollar una aplicación en Streamlit** que permita al usuario:
 - Ingresar o redactar una aportación científica o humanística en un campo de texto libre.
 - Visualizar la predicción de la categoría del Nobel estimada por el modelo, en una interfaz limpia y funcional.
 - La aplicación deberá estar BASADA EN EL CÓDIGO PROPORCIONADO, no se aceptarán aplicaciones creada con códigos .py distintos.
4. **Probar la aplicación:** Insertar las motivaciones adjuntas en el archivo "Test.csv" y obtener la predicción del modelo.

CUALQUIER CUADERNO QUE PRESENTE CÓDIGO HECHO CON IA SERÁ CANCELADO.

Entregable 2

Para la resolución técnica de este examen (Parte 1 y Parte 2), deberás estructurar tu cuaderno de Google Colab utilizando celdas de texto (Markdown) y de código, organizadas estrictamente en las siguientes cuatro secciones:

1. Ingeniería de Datos, Integración (Join) y Publicación en la Nube (Parte 1)

En esta sección deberás cargar las fuentes originales desde la web (URL de GitHub), unificar la información mediante un cruce (join), exportar el archivo consolidado y alojarlo correctamente en tu repositorio de GitHub.

Elementos obligatorios que debe incluir tu sección:

- Código en Python utilizando pandas para cargar ambos datasets desde sus respectivas URLs públicas.
- Realización del cruce (join) mediante las llaves correspondientes (por ejemplo, año y categoría).
- Código para exportar el resultado limpio a un archivo en formato CSV (df.to_csv(...)).
- Celda con el enlace directo en formato RAW de tu archivo en GitHub, el cual será utilizado como fuente de datos en vivo para tu dashboard de Power BI.

2. Procesamiento de Lenguaje Natural (ETL de Texto y Visualización)

En esta sección se presentará el ETL de las motivaciones históricas de los Premios Nobel para su modelado posterior y explorar su frecuencia léxica.



UAEM

Universidad Autónoma
del Estado de México



Elementos obligatorios que debe incluir tu sección:

- Limpieza y normalización del texto (conversión a minúsculas, eliminación de caracteres especiales, puntuación y stopwords en inglés).
- Vectorización inicial o preparación de los datos textuales.
- Generación y despliegue visual de una Nube de Palabras (WordCloud) utilizando las palabras más representativas del total de las motivaciones de los premios.

3. Modelado Predictivo, Evaluación y Matriz de Confusión

En esta sección se debe presentar el entrenamiento de un algoritmo de aprendizaje automático capaz de predecir la categoría del premio a partir del texto y evaluar cuantitativamente su desempeño.

Elementos obligatorios que debe incluir tu sección:

- División del conjunto de datos en entrenamiento y prueba (train/test split).
- Vectorización de características de texto (ej. CountVectorizer o TfidfTransformer).
- Entrenamiento del modelo de clasificación (ej. Multinomial Naive Bayes u otro algoritmo adecuado).
- Generación de las métricas de evaluación.
- Construcción, visualización e interpretación gráfica de la Matriz de Confusión para analizar aciertos y errores del modelo por cada categoría del Premio Nobel.

4. Desarrollo y Despliegue de la Aplicación Interactiva en Streamlit

Aquí adjuntarás las evidencias utilizadas para llevar el modelo predictivo a una interfaz web de Streamlit que permita a cualquier usuario realizar consultas en tiempo real.

Elementos obligatorios que debe incluir tu sección:

- El código fuente completo utilizado para el desarrollo de la aplicación (por ejemplo, el script en formato .py implementado con Streamlit).
- Celda con la dirección URL pública de la aplicación desplegada en Streamlit Community Cloud, lista para ser probada y evaluada.